细心从每一个细节开始

个人简历

Personal resume

基本信息

性 别男

姓 名吕舒宇

***4929

工作年限

2 年经验

电 话

邮 箱******@***

教育背景

太原理工大学(211)

计算机科学与技术(本科)

2021-09 ～2025-06

技能特长

・熟悉LangChain 生态与LangGraph 框架,熟练运用RAG 检索增强生成搭建低幻觉、高可用的企业级知_V P xlh识库与多智能体编排系统。

・熟悉BGE-M3 多模态嵌入模型与Milvus 向量数据库,可实现稠密+稀疏双向量混合检索,提升知识库召Y W O eim 回准确率。

・了解BERT 模型微调技术,可基于U _w I业u 4 务语料训练意图分类模型,实现闲聊过滤与智能问答请求路由优化。

・了解大模型LoRA 轻量化微调E ,1 R 完U 成模型业务适配,结合vLLM 实现高性能部署上线。掌握Ollama 本地大模型快速部署

・熟悉SpringAI 开发,熟1 H F 8 2 d 练运用Function Calling、MCP 协议搭建低幻觉、高可用的智能体核心。

・熟悉SpringBoot、b 2 Sc pb ringCloud Alibaba 微服务架构,熟悉Gateway、Nacos、Sentinel 等。

・熟练使用MySQ7 c 8 L3 e 数据库,Redis 及Redisson 框架,可实现分布式缓存与分布式锁。

・熟练使用E5 la ae s5 ticsearch 搜索引擎,可搭建分布式检索、日志检索及向量检索业务场景。

・熟练使用0 fR0 abbitMQ 消息中间件,实现业务异步解耦与分布式通信。

・熟悉XXL-JOB 分布式任务调度框架,基于可视化控制台完成任务CRUD、动态调整Cron 表达式。

・熟悉SSE 流式交互技术,可自定义事件规范实现文本与结构化数据分层推送。

・熟悉Linux、Docker 等工具,具备一定的项目部署与运维能力。

・熟悉Coze、Dify 低代码AI 开发平台,可快速搭建知识库RAG、智能体Agent 应用和编排AI 工作流。

・掌握Claude Code、OpenAI Codex,借助工具完成代码编写、重构与调试。

工作经验

深圳市云间网络科技有限公司

2025-06 ～至今

大模型应用工程师m

Java工程师y Y W O ei

2024-06 ～2025-06

智链数科信息技术有限公司

项目经历

2026-03 ～至今

智枢中台

大模型应用工程师d y-E 1 R U

技术框架:Python、FastAPI、LangChain、Milvus、MySQL、Redis、BGE-M3、BGE-Reranker、 BERT、BM25、WebSocket、RapidOCR、HyDE

主要职责:

1.多模态数据预处理工程化:定制多格式文档P O 解ei 析m 器,集成RapidOCR 识别图文与表格,支持GPU/CPU 双环境自动降级。过滤无效内容后统一封装标y Y 准W 文档对象,采用父子分块策略并差异化切割文本。基于BGE-M3 生成双向向量,在Milvus 创建索I引u 4 ,U _借助MD5 主键与Upsert 机制完成增量数据入库。

2.分层流量调度架构设计:构建轻量R U 化w 规则预筛+微调BERT 三分类的漏斗路由体系,实现闲聊、高频、深 度请求分流。高频咨询采用内d 存y-E B1 M25+Redis 缓存架构,规避磁盘IO,大幅降低大模型调用频次与成本。

3.增强型RAG 链路优化:2 H 基F 8 于LangChain 会话组件管控多轮对话上下文,设计HyDE、子问题拆分等多套 检索策略供大模型自适2 应c b 1 选择。串联向量混合检索、文档去重、BGE-Reranker 精排链路,优化召回准确率; 基于WebSocket c 实8 3 e 现b 流式交互,保障前端体验。

项目概述:

面向企业多业务线AI 落地痛点,设计并搭建企业级统一智能体中台,作为业务系H 2 c 统b 1 与大模型之间的中间层,解决AI 能力重复建设、技术栈碎片化、调用不可控、安全薄弱、模型强耦合等问题。支撑全公司多条业7 c 8 3 e b 务线低门槛对接大模型、智能体、RAG 知识库等AI 能力。

技术框架:Python、FastAPI、LangChain、LangGraph、Gateway、MOfO 5 a e ySQL、PostgreSQL、Redis、Elasticsearch、Nacos、SSE、RAG

主要职责:

1.网关搭建与集群流量管控:基于SpringCloud Gateway 搭建统一AI 接入网关,结合Nacos 实现服务注 册、健康检测与动态负载均衡。集成Redis 令牌桶限流、Resilience4j 熔断降级,管控调用频率、拦截异常 请求,减少Token 损耗,完成集群流量治理。

2.LangGraph 多智能体编排开发:基于StateGraph 构建有状态智能体编排引擎,采用意图识别、条件路 由、业务子智能体架构。借助大模型完成意图分类,通过配置化路由实现动态分支跳转,解耦业务代码。封装y Y W O e 通用智能体基类,依靠工具调用能力对接外部接口,框架可快速拓展新业务场景。