

从会话修订 到可复用能力

面向企业个性化智能体的技能涌现与持续演化

From Conversational Revisions to Reusable Skills:
Personalized Skill Emergence and Evolution for Enterprise Agents

01 全链路与技术机制

轨迹聚类、成功/失败分析、Patch归纳与真实复用

02 WWW Industry 技术对标

四篇论文的方法与证据；当前原型的真实边界

03 研究推进路线

原创机制候选、E1/E2/E3与完整论文大纲

证据状态 / 2026-09-24

构造数据的真实模型闭环已通过；尚无企业效果对照实验。

聚类、分角色分析和局部修改已接入；收益仍待评估。

概念讨论稿 v3，不作为投稿终稿或已证明创新的声明。

阅读导航

正文区分原型事实、待实现机制与论文证据。第八、十、十一节适合技术审阅；第九、十二节及附录适合安排后续研究。

一、这篇论文要讲什么	3
二、解决的具体问题	4
三、核心概念：任务、轨迹、经验与技能	4
四、完整链路：从员工会话到下一次更好的执行	6
五、一个贯穿全链路的例子	8
六、研究创新性与差异性应如何表述	9
七、为什么适合Industry方向，以及目前到哪一步	11
八、技术实现：轨迹聚类、分析器与Patch归纳	12
九、研究机制：可修订证据下的方法保留与受限归纳	16
十、当前判断：系统已超出单条 Prompt，但原创机制仍需验证	17
十一、技术实质与研究边界	18
十二、把当前原型推进成论文，最小需要补什么	19
参考来源与实现依据	20
附录A：实验计划E1、E2、E3	21
附录B：完整论文大纲	24

一、这篇论文要讲什么

企业员工与Agent一起完成工作时，常常经历“提出目标-得到初稿-指出问题-补充规则-再次修改”。这些反复解释和纠正不仅产生一份交付物，也暴露了员工的工作方法、业务约束、常见失误和稳定偏好。下一次遇到相近任务时，如果Agent仍需从头理解，前一次协作积累的经验就没有真正转化为能力。

本项目研究如何把这些经历转化为员工可选择、可审查、可重复使用的技能，并在后续使用中持续修订。关键不在于尽可能多地生成技能，而在于判断：**这段会话是否包含可迁移的方法？它是新方法，还是对已有技能的纠正？现有证据是否足够支持沉淀？更新以后，未来任务是否更好？**

我们提出的工作假设是：以可修订的任务轨迹为学习单位，结合实际技能使用证据和经验增量筛选，可以减少半成品、重复内容和无增量更新进入技能库，在保留有效方法的前提下控制模型与人工成本，并改善员工后续任务。

这是一个待检验命题。论文应最终回答“在什么任务和约束下有效，收益来自哪个机制，付出了多少代价”，而不仅展示一个功能完整的系统。

概念摘要

企业会话中的多轮修订、失败尝试与缺失验收反馈，使直接按问答对提炼技能容易割裂任务、保留错误中间稿，并产生大量缺乏复用价值的候选。SkillsLoop面向企业内部个性化Agent，将会话组织为包含目标、尝试、纠正关系、结果证据与技能版本的可修订任务轨迹；通过引用规则组织任务，按成员和技能版本隔离轨迹，以词法complete-link聚类形成学习池；成功、失败和未知结果分别提出有来源的方法修改，经多轨迹归纳与宿主校验应用，形成新建或更新候选，无增量证据不足分别记录支持或延期。生成的技能经用户采纳进入个人库，经组织审核后才能跨成员复用。执行时记录实际技能读取、输出及反馈，使后续更新可追溯到具体使用版本。拟通过候选质量、未来任务个性化收益和持续演化三个实验，检验系统能否在保留有效方法的同时降低无效沉淀与生命周期资源负担，并分析其工业适用边界。

以上是概念摘要，未虚构实验数字；正式投稿摘要必须在获得结果后重写。

二、解决的具体问题

当前问题	为什么影响企业使用	本方案的处理方向	需要证明什么
候选多、有用的少	员工需要反复审查，库不断膨胀	先判断任务与方法增量，再调用生成模型	无效数量下降，同时有效方法不丢失
问答对割裂任务	初稿和纠正版被当作独立成功经验	保留同一目标下多次尝试及纠正关系	错误中间稿传播减少，而非仅摘要更长
没有明确“满意/完成”	系统要么不学习，要么把沉默当成功	自动稳定封口，业务结果允许UNKNOWN	无验收反馈时仍可沉淀，且不伪造成功
使用技能的对话被忽略	最有针对性的修订经验无法进入技能	绑定实际使用版本，区分支持与更新	新实例改善，旧能力不显著退化
通用Agent不理解个人方法	员工反复说明格式、流程、业务口径	抽取条件化工作方法 with 稳定偏好	收益超出简单偏好摘要和原始经验检索
每次都模型分析和改写	学习成本可能超过后续节省	规则关联、精确去重、增量派发与资源记录	全生命周期成本可接受，不只外层次数少
个人经验直接变组织资产	容易混淆适用范围与共享授权	个人采纳、组织提审和审核分开	跨成员有效且边界清晰，而非默认共享

“十几个候选才有一个有用” 目前来自用户观察，尚未形成抽样统计，不能直接写成论文实测比例。

三、核心概念：任务、轨迹、经验与技能

任务是员工试图达成的一个相对明确的目标，例如“根据本周销售明细生成按部门汇总的周报”，通常有输入、约束和期望交付物。一个会话可能包含多个任务；一个任务也可能跨多轮修订。只有存在可靠引用时，才把跨会话内容关联到同一任务。

任务轨迹记录目标如何被尝试、失败、修正和交付，而非简单拼接全文。它至少包含：目标与约束、按顺序排列的尝试、纠正针对哪个输出、工具及产物引用、使用过的技能版本、技术终态和业务结果。技术运行结束与业务验收成功分开记录。

可复用经验是“在某种条件下应采取什么步骤、遵守什么约束、避免什么错误”。它可以来自成功，也可以来自失败后的有效纠正。一次结果数值、个人身份信息或无法解释的Bug不是可迁移方法。

Skill是可执行的经验包：适用条件、操作步骤、检查项、失败规避和必要参考资源，以SKILL.md及辅助文件保存。它不等于会话摘要；摘要说明发生过什么，技能说明未来在什么条件下如何做。

个性化包含员工稳定的工作偏好，也包含角色/流程特定的方法。个人偏好不得覆盖组织强制规则。比如“先给结论”属于表达偏好，“跨期退款不得计入本期净收入”属于有适用范围的业务规则，两者需要分别验收。

哪些材料值得进入学习过程

材料	默认处理	原因
有目标的任务及多轮纠正	保留并关联为轨迹	修订关系可能包含有效方法
用户没说满意，但已有交付	稳定后封口，结果UNKNOWN	无明确验收不妨碍提炼候选
有条件、有依据的失败规避经验	保留条件与来源	失败可能比终稿更有信息
一般事实问答	判断是否形成可复用过程	不能把所有问句都当噪声，也不把所有答案都做成skill
寒暄、无目标闲聊、模型自言自语	排除于技能生成，保留必要事件	缺乏任务与方法证据
网络超时等偶发基础设施错误	记录运行失败，通常不生成方法	不能将偶发现象泛化为业务规则；有验证的诊断方法另论
已用技能且无新方法的赞许	SUPPORT	增加支持证据，不为版本数反复改写
冲突反馈或多技能归因不清	DEFER	保留材料，避免把不确定性变成正式规则

四、完整链路：从员工会话到下一次更好的执行

01 SkillsLoop：从执行到下一次复用

蓝色：确定性控制 · 绿色：模型执行与封装 · 金色：人工采纳与授权



已跑通：构造销售数据 + 真实模型；未证明：企业效果、无效减少、成本下降。

已实现来源检查与局部修改；重要性排序、语义防退化仍需研究。

图1说明。实线表示已实现组件路径。024已通过单个构造销售案例的真实模型闭环；重要性排序仍待实现，尚无企业部署效果。聚类、三类分析角色与受控patch应用已接入；语义归纳、长期收益与资源目标的边界见第八节。

1. 采集完整交互事实

输入包括用户与助手消息、工具调用与结果、运行状态、交付物、选定技能及版本。保留原始顺序和稳定ID，避免只存“最后一问+最后一答”。采集事实与解释分开：工具失败是事实，“任务没有价值”是待判断的解释。

2. 通过引用与规则重建任务

优先使用显式任务/请求/产物引用，其次处理明确续作、纠错与新目标表达；歧义不强行关联。首次提出目标建立任务，后续补充和修订形成同任务的新尝试。目标明显改变则创建另一个任务。

当运行终止并经过稳定期，或会话达到空闲条件时，任务可暂时封口。封口仅表示当前材料可以整理，不表示已经成功。迟到纠正重新打开任务，形成新的证据修订，防止旧候选在依据改变后继续被当作当前结论。

当前实现是词法规则与精确关联的原型；对隐含指代、交错任务和跨会话延续的理解仍需真实数据检验。不能称其已解决通用任务识别。

3. 筛选方法材料，并聚合兼容的独立任务

先识别方法材料与可诊断失败，再检查精确重复。NEW在同成员内按规范化目标进行complete-link聚类；UPDATE按实际技能及基准hash聚池。默认每池最多8条独立任务，等待120秒吸收后续材料，单例到期也处理。同一任务多次纠正不算高频，聚类也不自动赋予共享权限。

重要/高频排序目前是待实现扩展：先从真实数据建立分布与业务标签，再决定是否需要额外排序模型。默认不为每段会话增加一次LLM价值评分。

4. 用实际使用关系分流，而非先做全库匹配

02 生成之前先决策

一次学习派发可能包含多次底层模型请求；四种路由不是四次模型调用。




图2：建议统一的候选决策语义。正常进入提炼后，模型仍可返回SUPPORT/DEFER；四种状态不是四次模型调用。这里“一次派发”不等于一次底层HTTP请求。实际门槛和规则需要由E1检验，不能把状态名本身当算法创新。

5. 分角色提议，跨轨迹归纳，应用局部修改

NEW/UPDATE的冻结轨迹池进入OpenClaw。成功分析器提炼步骤，失败分析器检查原因和修正依据，未知结果分析器保留明确用户规则；各自输出方法提议，再合并重复和互补经验。宿主检查引用、全部提议归属、基准hash和修改锚点，实际应用add/append/replace，最后用官方skill-creator封装。没有验证的失败原因只延期，不作为确定规避经验。

格式沿用现有SKILL.md结构及辅助材料，不把任务JSON当成技能正文。格式检查只能验证包是否可加载；真正有用与否则需要后续独立任务评估。

6. 经用户选择进入个人或组织库

用户可采纳到个人库，也可提交组织审核。提交不等于发布；组织审核通过的版本才能供其他成员选用。企业内出现相似任务，不代表个人会话自动获得共享许可。

个人修订与组织版本分开管理，更新校验基准版本，保留历史与回滚能力。这些是实现可信闭环的必要工程能力，不宜单独作为学术原创性主张。

7. 在后续新任务中真实使用

员工从有权使用的库中选取技能，OpenClaw获得该版本文件包及路径，实际读取SKILL.md和必要附件后执行。系统记录“选中-提供文件-实际读取-行为遵循-业务成功”的证据层级。

前三层可从运行记录获得；后两层需要独立业务验收。模型声称“已按技能完成”不足以证明遵循。消费阶段是测量方法有没有价值的必要环节，不能只评生成技能的文本质量。

8. 使用后的经验回流

后续会话不再因为使用过技能而被忽略。无增量使用积累支持证据；出现新约束、失误原因或有效纠正时，定位到实际使用版本并形成更新候选。反馈冲突、来源不足或归因不清时暂缓，不能把用户最新一句话无条件当真。

“自进化”在产品中表示自动发现和提出更新，在科研中必须进一步证明更新后的新任务收益。它不等于每次使用都自动发布新版，更不意味着绕过个人采纳和组织审核。


五、一个贯穿全链路的例子

以下为说明性案例，不是从企业数据库抽取的实证样本。

阶段	员工与Agent发生什么	系统应学到什么
首次任务	员工要求汇总销售周报	建立任务目标、输入和交付物
初稿失误	Agent把所有退款都扣到本周	记录错误尝试，而非成功经验
用户纠正	“先核对退款所属期，跨期退款单列”	保留错误与纠正的关系及适用条件
再次输出	Agent给出修正版，用户未明确确认	稳定后可封口；业务结果仍UNKNOWN
技能候选	将多次同类任务中的期间、退款和订单状态经验共同归纳	去掉重复、保留互补条件；每条修改有依据
下次复用	员工选择技能处理新一周明细	验证实际读取以及新任务是否正确
新反馈	“其中撤销退款要按本部门规则另列”	核验适用范围，形成有依据的UPDATE
更新后	新实例检查新规则，同时检查原退款规则	不因新增规则破坏旧能力

03 一条任务，多个修订

示例中的金额仅用于说明任务关系；状态封口不表示业务成功。



任一来源修订阻止旧候选入库；同池其他材料释放后重新归纳。

图3展示修订、候选失效与反馈回流，不是效果测量；多轨迹归纳及受控修改见图5。

前后区别是：旧方式可能把“错误初稿、正确修订、重复解释”分别变成多个候选；新方式尝试将它们组织成一条可修订证据链，形成较少且适用条件清楚的方法。是否真的减少错误并保留能力，由E1而非例子本身证明。

六、研究创新性与差异性应如何表述

6.1 已有研究覆盖了哪些内容

近邻工作	已覆盖的主题	我们不能再单独称为创新的内容	需要具体比较的方向
AutoSkill	从交互经验形成、维护和复用技能，积累个性化能力	会话变技能、跨会话个性化、持续更新	修订关系、缺失验收和资源约束下，是否仍有增量
Trace2Skill	从执行轨迹归纳可迁移技能，创建或深化技能	轨迹提炼、失败规避、技能更新	流式会话修订与批量轨迹归纳在相同资源下的差异
SkillClaw	利用多用户经验推动共享技能演化	多用户学习、共享技能持续演化	私有证据与审批边界内的收益、维护负担和使用归因

来源：AutoSkill v2、Trace2Skill v5、SkillClaw。这些近邻已足以否定“自动个性化技能闭环本身是空白”的说法；本表不表示对其所有实现细节已做穷尽排除，也不擅自断言它们没有任何类似修订机制。

6.2 最值得检验的三项贡献

C1：从静态对话片段转向可修订任务证据。

困难是经验来源会随迟到反馈变化，初稿可能已失效，且没有明确成功标签。拟研究的机制是把目标、尝试、纠正关系和结果证据共同作为沉淀依据，使候选与来源修订保持一致。研究增量应体现为错误方法传播或有效方法丢失减少，而不只是实现一个任务状态机。

验证方式：完整会话强摘要、简单任务分段、不可重开与可重开对照。如果强摘要已同等处理，不能继续宣称复杂任务机制具有独立优势。

C2：围绕方法增量分配学习资源，而非每段对话都生成。

困难是冗余候选和无增量更新同时占用模型与人工。拟研究的机制是结合任务方法证据、实际使用版本和已有覆盖，决定新建、更新、支持或延期。资源分配与能力保留共同验收，不能靠全部拒绝或长期排队制造“低成本”。

验证方式：固定流量与固定总预算两套比较，报告无效数量、有效方法保留、后续任务收益和全部成本。规则过滤、去重、预算限额各自都是常见手段；只有具体机制及其可重复收益才可能支持方法贡献。

C3：在个人适用范围和版本证据下检验持续改善。

困难是个人习惯、组织规则和单次纠正容易混在一起，盲目更新可能损害原有能力。拟研究的机制是将反馈绑定到任务、适用条件和实际使用版本，以未来任务和旧能力检验更新，而非以“生成了新版本”作为成功。

验证方式：与个人偏好摘要、原始经验、冻结库及定期重写比较。这个贡献最容易与AutoSkill等重叠，当前应作为候选系统/实证贡献，待机制比较后再决定是否具有独立算法创新。

6.3 本项目的独特定位，而非已证明的排他性

本项目强调的组合是：**真实员工会话中的不完整证据、无需额外完成按钮的轨迹修订、以少生成和少改写为目标的增量沉淀，以及个人采纳和组织审核边界内的持续复用**。这些要求来自同一个企业场景，彼此影响：过滤过严会漏掉方法，更新过勤会增加成本，共享过快会改变授权边界。

潜在独特价值在于给出这一组约束下可运行、可测量的解法与经验，而不是换一个技能格式或复刻Trace2Skill。当前可称“有明确差异化研究定位”，不能称“全网首次”“唯一方案”或“原创性已经成立”。

6.4 贡献-证据对应表

贡献候选	必须出现的可观察证据	不足以支持它的证据
C1可修订证据	相同来源和消费者下，纠正关系改变技能规则并改善新实例	流程图更完整、JSON字段更多
C2增量学习	同预算/同流量下无效更少、有效方法保留、延期透明	只报告生成量和外层调用数下降
C3个人演化	同用户未来任务受益，且更新相对冻结库有净收益	满意度上升、版本号增加、重复题分数提高
工业价值	真实工作负载、独立验收、审核维护计入后的净收益	单次控制技能通过或软件测试数量

七、为什么适合Industry方向，以及目前到哪一步

论文要把方法嵌入真实企业问题，解释输入噪声、权限、人工审核和成本约束如何影响设计，再展示可量化的任务收益与失败边界。WWW Industry强调实际问题、系统取舍和工业影响；并不意味着闭环做出来就足以投稿。既有要求与案例详见020论文蓝图。

层面	当前状态	写作边界
企业场景	用户已有InsightWeaver；本阶段独立demo	可写应用背景，不能写新增算法已上线
基础闭环	规则轨迹、任务聚类、三类分析、patch合并应用与版本复用	可介绍实现；通用关联、重要性及净收益未证实
真实模型	024真实生成、官方封装、v1消费、v2更新和组织消费通过	构造销售数据功能验收；非企业效果实验
资源控制	外层学习派发额度	不能等同内部HTTP/token硬预算
算法效果	尚无真实企业对照实验	无效减少、有效保留、成本下降均是目标
生产价值	尚无新增算法的部署试点	工时、采用率、跨成员收益不能预填

下一阶段的重点是取得真实会话与独立验收，将候选创新变成可被否定的实验。首批材料见数据交接清单；代码工作包与实施顺序见021执行计划。

八、技术实现：轨迹聚类、分析器与Patch归纳

8.1 数据表示与学习对象

SkillsLoop将连续会话整理为可修订任务，再将兼容的独立任务聚为一个学习池。学习对象是带适用范围、来源和局部文件操作的方法修改。模型参数固定，变化的是技能目录。

轮次e包含消息、技术状态、实际使用版本、工具调用与可见结果、运行ID、产物路径及hash。轨迹T(r)保存目标、有序轮次、修订r、内容hash和封口状态。可见工具结果每条最多8,000字符并标记截断；学习时按权限及hash核对来源产物，将不超过2MB的文件复制到证据目录。缺失或过大文件标记不可用，不冒充完整证据。

学习池P冻结多个T(r)、权限边界、路由和基准技能S(v)。每个提议p包含lesson、applicability、evidenceType、evidenceRefs及可选diagnosis。合并结果记录proposalIds和operations。候选保存提议、归属、延期原因及应用回执。

SEALED仅表示暂时稳定；FILE_READ仅证明读取；包验证仅证明格式。三者均不能推出任务成功或方法有效。


8.2 从会话形成可修订轨迹

关联优先使用原taskId和本人显式replyTo，再处理明确续作、纠正、对模型单一询问的反馈以及新目标。歧义不强制合并。无运行中回合且达到稳定或闲置阈值后封口；迟到纠正重开任务并增加修订号。

hash覆盖消息与已登记工具、产物、评估信息。任一来源修订使依赖它的待生成或待采纳候选失效；同池未变化任务释放回待聚池集合，避免一条纠正吞掉其他方法。当前失效粒度仍是整个候选，不是已发布方法的自动局部撤销。

04 轨迹小模块：关联、修订、封口

消息、工具结果、产物引用共同进入hash；隐含语义关联仍是边界。



任务识别仍是显式引用和词法启发式。隐含指代、交错任务、弱目标表达需要真实会话检验；关键词不是价值证明。

8.3 聚类、路由与冻结池

按实际使用关系确定NEW或UPDATE，不检索全库猜测更新对象。选中但未观测到读取、多技能归因不明、混合基准版本时延期。真实FILE_READ与合成SIMULATED分开；已用技能且无纠正或失败依据时走SUPPORT。

NEW聚类。同一成员内规范化目标：去除任务前缀和数字，合并少量词法变体，提取英文词和中文二元组。词频向量余弦相似度默认阈值0.72；新任务必须与簇内每个任务都达标，即complete-link约束，避免A接近B、B接近C就错误合并A与C。这是不调用模型的词法聚类，可能漏掉不同表述的同类任务，不是通用语义理解。

UPDATE聚池。以owner、实际skillId、baseHash为硬边界，同一版本的独立执行共同提出修改。技能提供任务范围锚点，更细的业务条件由applicability与归纳处理；版本相同不等于所有条件相容。

每池最多8个独立任务，并设输入长度限制；同任务的多次修订不算独立样本。服务默认等待120秒吸收材料，单例到期仍处理，不要求高频才能沉淀。派发后冻结，不再增加来源。精确重复记录为支持；业务重要性排序尚未实现。

8.4 成功、失败和未知结果分析器

三个角色共享冻结基准，逐轨迹提出修改，再跨轨迹归纳。当前在一次OpenClaw学习派发内执行，以约束外层调用；不等同于Trace2Skill独立并行子Agent。分析器读取官方skill-creator规范及可用产物。

角色	进入条件	输出与校验
成功分析器	用户明确验收或报告通过的评估	提取步骤、条件和引用；结果通过不证明每一步有因果作用
失败分析器	用户纠正或报告失败的评估	原因、修正和验证引用；观察类失败经验无原因及通过的check则延期；用户明确规则可单独提议
未知结果分析器	缺少结果依据	用户规则可提议；无验证猜测仅作为MODEL_HYPOTHESIS延期

导入checks含name、expected、actual，来源标为IMPORTED_EVALUATION；值比较反映外部提供的评估，不等于宿主重新执行独立验收。用户纠正证明存在反馈，不自动证明旧执行错误或失败原因成立。

这继承Trace2Skill的分析分工。论文的失败分析包含主动验证；当前提供证据/产物检查与验证引用约束，通用业务oracle及诊断修复后的独立再执行仍未自动化。引用校验不能称为因果证明。[Trace2Skill §2](#)

8.5 多轨迹Patch合并与实际应用

模型先输出逐轨迹提议，再按重复、互补、条件差异和冲突形成many-to-one合并组。每个提议必须归入一个合并组或带原因的延期项，宿主拒绝静默遗漏。小池采用一次归纳层，没有默认多层独立模型合并，不能称严格复现论文。


宿主检查eventId及quote，区分USER_RULE、OBSERVED和MODEL_HYPOTHESIS。随后实际执行add新增文件、append追加内容或replace替换唯一原文片段。append/replace须匹配冻结文件hash；replace锚点必须唯一；UPDATE禁止整文件覆盖和删除。相同操作只执行一次，冲突或过期操作使本次生成失败并保留记录，不静默选择最后一项。

NEW从弱的确定性SKILL.md骨架开始，UPDATE从真实基准开始。最终文件由宿主应用接纳操作得到，再由官方creator校验封装；模型直接提交完整files不能绕过此过程。结构化patch让修改可检查，但不能保证语义正确或旧能力

不退化。

05 多轨迹分析与Patch归纳

一次学习派发内分角色分析；小池一次归纳；宿主实际应用修改。



来源可审计不等于语义正确；未知原因不升级为已验证经验。

```

on_turn(e):
    T = associate(e); revise_and_invalidate_if_changed(T)
on_cycle():
    seal_stable_tasks(); route_by_skill_use_and_evidence()
    P = complete_link_NEW_or_same_version_UPDATE_pool()
    freeze_after_wait(P)
generate(P):
    check_all_sources_and_base(); reserve_dispatch()
    proposals = analyze_success_failure_unknown(P)
    merged, deferred = consolidate(proposals)
    check_citations_coverage_and_patch_preconditions()
    files = apply_to_frozen_baseline(merged)
    creator_validate_and_package(files)
    recheck_all_sources(); retain_candidate_for_adoption()
  
```

8.6 入库、消费与演化

个人采纳和组织审核前复核全部来源，不能只检查第一条。更新检查基准版本/hash；组织技能的个人修订形成个人分支，跨成员使用仍须组织审批，聚类不扩大原始会话访问权。

消费时将获准版本写入OpenClaw工作区；实际读取登记原生回执，产物登记路径与SHA256。后续纠正再进入对应版本池；无增量SUPPORT不强行改版，无法解释的失败保留延期。

8.7 复杂度、资源与实现边界

构造数据的真实模型验收已完成：3条独立来源轨迹归纳为1个NEW，2条实际使用反馈合并为1个UPDATE；官方封装、个人采纳、组织审核和另一成员消费均通过。新输入的净额170/325及新增字段由宿主检查；35项软件测试通过。成功批次共5次派发、24次内部请求发起、306,250报告tokens；另有网络拒绝的1次派发/8次请求尝试，usage未知。没有同预算基线，不能由此推断成本下降或企业收益。验收证据

设T为待发现任务、L为目标特征长度，complete-link聚类最坏含O(T²L)比较；每池最多8条约束单次模型输入，没有消除全局扫描。任务关联仍扫描、排序，历史修订保存完整快照。当前没有大规模增量索引或吞吐优势实测。

分析与合并共用purpose=learn及每日额度，失败计数，同runId不自动重复派发。一次外层调用可含多个内部模型请求：派发是硬限制，总tokens仍是软约束。候选变少不直接证明费用下降，审核、等待、延期遗漏与消费成本均需核算。

024历史功能案例为6次外层派发、35次内部请求发起、498,204报告tokens（含缓存，非账单，未含此前诊断失败）。这是旧功能基线，不是当前多轨迹成本。缺失价格保持UNKNOWN。历史验收

层次	已实现	待验证或补齐
轨迹与聚类	修订、complete-link、版本隔离、等待聚池	企业任务召回、误合并、重要性排序
分析与归纳	三类角色、逐轨迹提议、合并、延期覆盖检查	语义正确性、复杂失败主动验证、多层分析收益
更新执行	引用/hash/锚点校验、实际patch应用、官方封装	语义矛盾、旧能力退化、已发布条目局部撤销
治理与消费	审批、回滚、真实读取、交付物	生产认证、部署和长期收益
资源	聚池、精确复用、统一额度与记录	内部tokens硬预算、完整费用、同预算优势

九、研究机制：可修订证据下的方法保留与受限归纳

研究焦点是迟到修订、未知结果与资源约束如何改变技能归纳。聚类、patch池及成功/失败分工已有相关基础，不能单独声称原创，必须用强对照验证本项目处理策略的额外作用。

9.1 来源修订后，哪些方法应保留

当前保存多来源及逐条引用，修订阻止旧候选入库并释放同池其他材料。下一步研究条目级撤销：只删除失效依据支持的经验，保留仍有支持的方法；缺少语义依赖时不能声称精确识别影响范围。

9.2 合并减少重复，还是掩盖有效方法

目标是在兼容范围内归纳互补规则并分开冲突条件，不是强制所有材料只生成一个skill。结构校验发现未分配的提议，却不能发现模型提出提议前的漏学。E1必须从原始合格材料独立标注，检查来源→提议→合并→技能各阶段的方法保留率。

9.3 UNKNOWN与失败假设

UNKNOWN正常分析，明确用户方法可成为候选，但效果仍未知。无验证失败原因只能延期。需比较漏学成本与错误传播，不能仅报告过滤率。

9.4 预算与防退化共同验收

同一来源流量比较旧单轨迹、强批量摘要、证据patch归纳，固定消费者，核算生成、验证、失败、消费及人工维护。以共同初始库比较演化与冻结版本，使用新实例和旧能力检查。强摘要若等效则收缩机制；成本不增与原创贡献仍待实证。

十、当前判断：系统已超出单条 Prompt，但原创机制仍需验证

当前 SkillsLoop 是由可修订轨迹、范围约束聚类、分角色分析与受控 patch 应用组成的系统原型。它具备多轨迹归纳与可执行修改契约，并接通封装、真实消费和反馈回流；语义归纳仍依赖模型，旧能力保持及企业净收益尚待独立评估。实现更完整不自动证明原创贡献。

技术复杂程度不是 Industry 论文的独立录用标准。WWW 2026 官方强调工业环境中的原创成果、真实问题、可测影响、设计取舍与可迁移洞察，且要求交代部署或发布方式及持续时间；相较 Research 更偏实际适用性，不免除原创与证据要求。本文按 2026 已发表样本对标，不将 2026 征稿日期/篇幅直接套用未来投稿年份。[1]

10.1 对标样本与资料范围

本节选取四篇 WWW 2026 Industry 论文作为技术参照，覆盖 Agent workflow、数据闭环、知识增强和系统效率。论文归属以大会官方日程为准，方法和实验以作者公开全文为准。样本用于说明常见的技术论证方式，不代表整个 Industry Track 的平均水平。[2]

文中数字均为论文报告值，未做独立复现。

10.2 四篇论文：技术实质在哪里

A. When Rules Fall Short: Agent-Driven Discovery of Emerging Content Issues in Short Video Platforms.

方法§4把未知问题发现分成疑似召回、现有政策覆盖判断、变体/新问题区分；后者有流式分配与离线聚类，Agent可用专门治理模型、多模态向量或长期记忆。§6包含工具消融、分阶段分析与在线治理效果；新问题观看占比相对下降 14.9%，流程 25.8 天缩至 7.7 天，但 Agent 约 12.5 H100 小时/日，SFT 约 1.7。技术价值是问题分解、外部证据与治理闭环，且坦诚计算代价，而非一句自动更新政策提示。[3]

B. Make It Long, Keep It Fast: End-to-End 10k-Sequence Modeling at Billion Scale on Douyin. §3使用目标到历史的堆叠交叉注意力，序列复杂度由二次降为线性；请求级批处理复用同一用户历史编码，并结合短训练/长推理。§4检查精度、FLOPs、带宽和吞吐；请求批处理报告 2.2 倍端到端训练吞吐，进一步内核优化后 5.1 倍。这里是明确的模型结构与系统计算重排，本项目目前没有同等级别的性能优化证据，也无必要照搬其训练路线。[4]

C. Data-Driven Function Calling Improvements in Large Language Model for Online Financial QA. §3的 AugFC 用全局/簇内参数熵发现分布盲区，仅在多样性改善时接纳增广，再做 SFT 和 GRPO。§4区分盲区检测、分布感知 prompt 和多轮增广的贡献；§5评 350 个端到端问答对，约 2,000 个问题-调用列表，工具执行与最终答案分测。它确实依赖 prompt，但提示之前有可计算的“补什么”判据，之后有结果门槛和组件消融。[5]

D. CardRewriter: Leveraging Knowledge Cards for Long-Tail Query Rewriting on Short-Video Platforms.

§3组合规则/向量召回、平台多源知识卡与改写，训练奖励同时考虑相关性和检索效果，用 Bradley-Terry 模型近似系统偏好。§4比较知识源、奖励与卡片生成方式；10 天线上实验中覆盖流量约 16%，CTR 在覆盖流量和全流量分别为 +3.729% 与 +0.342%。贡献包括领域证据组织、目标对齐与线上效果，不能概括成“把卡片塞入 prompt”。[6]

10.3 从这些样本能得到什么，不能得到什么

可以看到三条有效的论证路线：workflow 与证据组合有独立作用；数据筛选/增广机制有明确判据；模型与系统计算改变带来规模收益。这些路线不要求每篇都具备新网络、训练算法和复杂数学。上述 Agent 政策发现方案本身就大量使用现成组件，但作者解释了组合解决的工业难点并量化效果。

因此，不能得出“必须上 RL/多 Agent 才够技术”的结论。更合适的检验是：拿掉你的专有机件，只保留同模型、同信息、同预算的强 prompt，效果和运行行为是否仍然一样？若一样，新增架构没有获得研究支撑；若存在稳定差距，还需解释产生差距的机制与适用边界。

对本项目的直接启示是：**生成前的决策要能计算、重放和做消融，最终还要落到后续任务收益上。**

十一、技术实质与研究边界

维度	当前机制	仍需证据
任务与聚类	引用和词法关联，NEW完整链接聚类，UPDATE实际版本聚池	真实任务召回、误合并、语义不同表述
证据一致性	多来源hash，迟到修订阻止采纳，未变化来源重新排队	已发布条目的局部撤销与方法保留
经验提炼	成功/失败/未知角色，来源原文引用，假设延期	归纳正确性、失败诊断的独立验证
修改执行	提议全覆盖，局部操作，基准与唯一锚点校验，官方封装	语义矛盾和旧能力退化
资源	等待聚池、统一学习额度、幂等运行和用量记录	同预算优势、内部token硬限制和现金费用
工业证据	可运行原型及构造数据功能验证	企业工作负载、真实员工及长期净收益

11.1 模型负责什么，代码保证什么

模型负责从证据解释方法、判断条件、提出修改并作跨轨迹归纳。代码负责材料与版本隔离、聚类门槛、引用存在性、提议处理完整性、局部修改应用、过期拦截和审批。来源引用有效不证明语义推导正确，格式验证不证明业务能力保持。

因此，当前技术超出单次文本prompt：同一模型输出可能因不存在的引用、遗漏提议、过期基准或冲突锚点而被拒绝，其修改必须经过宿主实际应用。但这些控制机制单独并不新颖，仍需证明它们在企业可修订会话下带来的可重复净收益。

11.2 与Trace2Skill的关系

逐轨迹patch、成功/失败分工和many-to-one合并借鉴Trace2Skill，应在论文中明确归因。当前选择一次Agent派发内的批量角色分析与小池归纳，补UNKNOWN和迟到修订处理；没有复现其独立并行子Agent与多层merge，也没有新增模型训练。不能将同一机制重新命名作为创新。[Trace2Skill方法](#)

11.3 原创性仍由什么决定

AutoSkill已覆盖交互经验提取和持续维护；Trace2Skill已覆盖轨迹归纳。差异应落在证据会被撤销、结果未知、无额外用户标记操作和学习预算受限时的方法保留策略。完整会话强摘要、强批量摘要和近邻适配必须作为对照；若效果相当，应缩小机制主张。

十二、把当前原型推进成论文，最小需要补什么

12.1 推荐定位

保留论文主标题，技术副标题可用“可撤销任务证据与受预算约束的技能增量学习”。这比泛泛强调Agent自进化更清楚，也不承诺未经验证的全面领先。正文围绕第九节的机制A/B，预算作为设计约束，治理作为系统边界；不把三个未成熟模块分别包装成三项原创算法。

工作包	具体产物	完成条件	对应问题
P0 真实问题审计	去标识会话、任务/纠正/方法标注、失败类型表	能统计QA割裂、迟到纠正、未知结果和方法稀疏现象	问题是否足够真实且普遍
P1 机制深化	在已有聚类、提议和patch应用上补局部撤销及独立诊断验证	修改来源可回溯；未失效方法保留；假设和结果分开	新增机制是否产生额外收益
P2 成本契约	全模型请求账本、token/缓存/失败口径、预算控制	外层与内部可核对；超限行为与延期透明	“至少不增加成本”能否验收
P3 强对照	完整会话强摘要、简单分段、近邻适配、相同消费者	相同信息与资源；冻结提示和选择流程	自有机制是否必要
P4 真实使用	授权员工试点、任务验收、审核维护计时、部署记录	真实全量合格任务可核算；退化与失败完整报告	是否足以支撑工业价值

12.2 E1/E2/E3要额外回答的机制问题

E1增加纠错条目审计。分别统计已被推翻规则仍被保留、未失效规则被误删、无依据规则被添加。对比完整会话强摘要、仅未稿、整轨迹重生成和局部证据处理。不可只统计候选更少；从所有合格会话抽样，才能发现被规则漏掉的有效方法。

E2增加“摘要足够吗”检验。同一未来任务比较无技能、个人偏好摘要、原始经验检索、强摘要生成skill与本方法skill；固定实际消费模型和可用上下文预算。若收益只是增加上下文或记住格式偏好，应收窄贡献，不归因为复杂轨迹算法。

E3增加修订时序与反例。先测未见任务，再释放反馈更新，下一轮换新实例；同时检查旧能力。加入迟到纠正、相互冲突反馈、仅修改数字、单次业务例外和连续无增量使用。观察局部机制是否比冻结库或整包重写更稳定。

这些是对原E1/E2/E3的补充，具体步骤保留在附录A。无需现在扩跑大规模实验；先用少量获授权样本验证定义和判定是否可操作，样本量再依据任务分布与目标效应确定。

12.3 何时应收缩而不是加复杂度

如果完整会话强摘要在同预算下已保留纠正、减少无效产物，C1应降为实现设计；若条目级结构增加审核负担且没有收益，不保留为主方法；若生成成本降低但消费成本上升，不能只报学习阶段；若只在构造销售模板中有效，先限制适用范围，不能外推企业通用任务。

当前成熟度判断：可运行的研究原型，尚未达到可凭已有证据支持Industry投稿的状态。最大差距是可辨认的机制收益和真实工业证据；单纯增加prompt长度、agent数量或流程节点不能弥补。可行路线是做深一个受现实约束驱动的机制，再用强简单基线证明它值得存在。

参考来源与实现依据

1. WWW 2026 Industry CFP: Scope、部署/发布说明要求、审稿侧重点。未来年份须重新核对。
2. 大会官方存档完整日程：Industry 7及Industry Track海报段，用于核实四篇归属。
3. When Rules Fall Short, arXiv v1: §4方法；§6.2线上/效率/资源；§6.3分阶段结果。
4. Make It Long, Keep It Fast, arXiv v1: §3.1-3.3；§4.2-4.5。版本可能不同于出版终稿。
5. Data-Driven Function Calling Improvements, arXiv v1: §3.2.4 AugFC；§4.5消融；§5.2端到端评估。
6. CardRewriter, arXiv v1: §3.1-3.3；§4.3消融；§4.4及表3线上指标。
7. AutoSkill v2: 作者摘要及版本记录；仅用于近邻范围定位。
8. Trace2Skill v5: 方法第2节及版本记录；用于界定借鉴机制和实现差异。

本地技术依据：`engineering/demo/skilldemo/core.py`的`classify`、`_record`、`tick`、`discover`、`generate`、`accept`；`runtime.py`的`run`；`live.py`的原生读取证据；`bootstrap.py`的初始化与封装；024验收与024记忆。当前多轨迹实现见`learning.py`、`MULTITRACE_SPEC.md`及测试记录；历史024数字不作为新算法效果。文献评估和功能验收不等于企业效果实证。

附录A：实验计划E1、E2、E3

用户所写“EE2”在本文统一为E2。三个实验分别检验“沉淀质量、未来个性化收益、连续更新收益”，不要用一个综合分数替代三个问题。

06 三个实验，三个不同问题

保持时间隔离：先执行并评分，再释放反馈更新；不把未来答案带入生成。



工业证据另需真实员工试点、授权范围、运行周期与净人工时间。此图没有结果数值。

图6为拟议评估设计，无实验数值。E1/E2/E3步骤保留，补充机制问题见第十二节。

E1：能否少生成无效技能，同时保留有效方法

研究问题。任务轨迹与增量筛选是否提供超过完整会话摘要的收益？减少产物是否只是漏掉了有效方法？

所需输入。完整真实会话，包含修订、失败、未知结果、无价值问答和未产生技能的流量；独立标注的有用方法参考集；用于消费的新实例。不能只导出已被系统选中的候选来源。

对照。G0原问答对链路；G1强完整会话摘要→skill；G2规则任务分段→skill；G3与本方法使用相同聚类 and 相同来源的强批量摘要→完整skill；O为证据patch归纳。G3用于区分聚类收益和patch机制收益。AutoSkill、Trace2Skill作为近邻时区分官方复现与本地适配，后者的可靠结果标签子集与UNKNOWN子集分别报告。

执行步骤。

1. 冻结早期生成区间、中间开发区间、后期测试区间；同一任务及衍生实例不跨集合。
2. 在看算法候选前标注方法、条件、纠正关系和未知项；两名业务评审先独立校准部分样本。
3. 各方法使用相同来源机会、生成模型、格式与审核标准；不强制候选数量相同，不截掉强基线纠正内容。
4. 在自然流量下统计真实资源；另做相同总资源上限比较，说明超预算排队与覆盖损失。
5. 对候选盲审，并用未见过的新实例验证方法实际有用；检查skill内容、读取和最终行为，分离错误位置。

主要指标。无效候选绝对数及比例；被有效技能覆盖的参考方法数/全部参考方法数；有效、无效和待评候选分别计数；重复率、审核分钟数、请求/tokens、失败重试和延期；后续任务成功率作为效用证据。

消融。完整轨迹/仅终稿；不可重开/可重开；同预算有无增量筛选。其他环节固定；联合修改不作单一机制归因。

决策标准。候选减少但有效方法丢失超过预设业务容忍范围，则目标未实现；完整摘要已等效，则缩小C1；只有增加预算才改善，则不支持C2资源主张。容忍范围在看正式结果前确定。

交付。候选与来源清单、方法覆盖矩阵、资源账本、主对照与消融表、失败案例及可复核运行记录。

E2：个人技能是否改善员工未来任务

研究问题。收益来自可复用工作方法，还是简单记住偏好或增加上下文？

所需输入。同一员工较早的学习材料、较晚的独立任务、业务约束与个人偏好标签、输入附件、独立验收规则。只有一段历史对话时可构造受控新实例，但必须标明其不是自然未来流量。

对照。C0无技能；C1检索原始经验片段；C2简短个人偏好摘要；C3已批准组织通用技能（存在时）；C4自动个人技能。必要时加入专家技能参考，人工制作时间计成本。

执行步骤。

1. 仅用早期材料生成个人技能、偏好摘要和经验索引，不暴露未来答案与纠正。
2. 固定底层模型、工具、任务输入、超时和资源口径，各条件使用独立会话/工作区。
3. 先在明确给定适用技能下比较方法效用，再测真实用户选取流程；后者计入误选、未选和未读。
4. 客观字段/规则用独立程序验收，开放文本匿名盲评；业务正确性和偏好符合度分开。
5. 按用户、角色、任务族和历史稀疏程度报告收益与退化。组织约束不能被个人偏好覆盖。

主要指标。全部合格任务上的业务验收成功率；个性偏好遵循、重复说明次数、返工主动时间、全部模型成本；记录选中→读取→遵循→成功漏斗。没有操作计时就不声称客观节省工时。

决策标准。若个人偏好摘要已同等有效，不能将个性化收益归因于复杂skill机制；若只在人工选中时有效，应将结论限制在该条件；若平均改善但部分角色受损，必须报告并收窄适用范围。

交付。未来任务结果表、角色/用户分层结果、偏好与业务错误分解、成本与人工负担表。

E3：持续演化是否比冻结技能更有价值

研究问题。反馈是否带来新任务收益，还是只让当前题目更熟、版本更多或旧能力退化？

所需输入。共同初始库、按时间排列的独立新任务、对应反馈依据与时点、旧能力审计集和适用范围变更信息。

对照。冻结库；固定周期重写；O增量更新。各分支从同一初始版本开始，使用隔离库和可比较执行资源。

执行步骤。

1. 在时刻t，各分支使用各自当前版本执行新任务。
2. 锁定输出、评分、成本与时间；评分答案不进入生成器。
3. 才释放该时刻允许的反馈并更新；超预算排队，记录等待。
4. 下一时刻使用新实例测试，另用保密旧能力集检查退化；不将审计评分回灌更新。
5. 连续覆盖多个真实更新机会，记录冲突、无增量赞许、错误反馈与拒绝更新。

历史纠正针对旧答案时，不能直接充当对新答案的反馈。共同回放必须限于独立核实的业务事实，并标为离线共同证据；真实交互反馈需评审当前输出。模拟用户必须单列。

主要指标。累计新任务成功、累计总成本、更新有效率、旧成功→新失败比例、旧失败→新成功、审核维护时间、延期和冲突。一次更新成功不等于长期演化有效。

决策标准。仅在已见修正例改善而新任务不改善，不支持泛化；新版收益被旧能力退化或维护成本抵消，则不支持净改善；若冻结库已等效，应限制更新频率而不是强制不断演化。

交付。版本-证据谱系、累计收益/成本曲线、退化矩阵、更新/拒绝/延期事件、典型正负案例。

三个实验共用的约束与启动顺序

- 024已解决真实CLI收尾；下一步补完整批次成本计量，再做数据审计和评分校准，然后E1→E2→E3。首轮可先取少量不同任务族定位机制，不据小样本宣称总体提升。
- 正式规模依基线成功率、最小业务有效效应和用户/任务族相关性确定；不能把一次技能的几十次消费算成几十次独立生成。
- 成本包括生成、消费、验证、更新、失败重试及人工审核；缓存计量单列，缺失费用为UNKNOWN，不能填0。
- 有效方法保留与成功率的非劣容忍度事先确定；不显著下降不等于已经证明不下降。报告合适的配对/聚类置信区间与方法随机性。
- E1-E3即使通过，仍需真实员工使用、净人工时间和运行周期证据才能有力支撑工业价值。组织试点/E4保留在021计划，不因本附录聚焦三实验而取消。

附录B：完整论文大纲

以下延续上一轮约8页正文的工作分配，**不是对未来投稿年份页数规则的承诺**。参考文献及附录按目标年份官方要求另核对。

Title

From Conversational Revisions to Reusable Skills: Personalized Skill Emergence and Evolution for Enterprise Agents

题目突出材料特点、研究对象与使用场景；不提前承诺资源下降或性能领先。若最终只有离线结果，可在摘要明确 prototype/offline evaluation；不在标题写 “deployed at scale”。

Abstract (约0.5页)

写清企业问题、核心机制、真实评估设置、主要收益与代价、适用边界。最终按 “问题→方法→证据→结论” 组织；当前以本文概念摘要为起点，结果部分保留待补。

1. Introduction (约0.8页)

1. 企业员工反复纠正Agent，却无法跨任务积累方法的动机。
2. 一个经去标识且有证据的真实案例：QA原子如何留下错误经验。
3. 缺失验收、持续修订与资源约束共同造成的挑战。
4. SkillsLoop核心思想与C1-C3贡献；仅保留实验能够支持的部分。

需要材料：真实问题发生分布、案例原始依据、人工/资源代价。

2. Industrial Setting and Problem Definition (约0.6页)

- 2.1 InsightWeaver背景、用户角色、任务入口与已有流程；独立研究环境与生产环境的边界。
- 2.2 定义task、attempt、trace、skill、经验增量、个人与组织范围。
- 2.3 目标与约束：方法保留、后续成功、总成本、版本退化与审核授权。把它们写成研究目标，不能把启发式描述成已求解最优算法。

3. Related Work (约0.5页)

- 3.1 会话经验与个性化技能：AutoSkill等。
- 3.2 轨迹归纳与经验记忆：Trace2Skill、AWM、ACE等，正式引用前核对版本。
- 3.3 技能演化与评估：SkillClaw及相关基准。比较具体机制与评估条件，不写未经证明的 “现有工作均不支持”。

4. Method: Revisable Evidence and Incremental Skill Learning (约1.6页)

- 4.1 执行事实采集及来源关联。
- 4.2 任务关联、尝试/修订关系、UNKNOWN结果、封口与重开。
- 4.3 按成员和实际版本划分轨迹池；NEW complete-link聚类，UPDATE版本聚池；区分成功、失败及UNKNOWN分析。

4.4 逐轨迹patch、多对一归纳、来源与覆盖校验、局部应用；等待窗口、统一学习额度、冲突延期及版本一致性。

配图：全链路图、轨迹修订图；算法框给出实际执行步骤和成本组成。未实现的重要性排序只能作为扩展，不能写入已评方法。

5. System Implementation and Operational Setting (约0.6页)

5.1 独立OpenClaw消费、完整包、实际读取与产物证据。

5.2 个人采纳、组织审核、版本检查和回滚。

5.3 原型工具范围、存储、延迟/失败/重试、权限与部署边界。未完成生产试点时不把本节写成已上线Deployment。

6. Evaluation (约2.5页)

6.1 真实数据与任务族、时间/用户拆分、来源与验收授权。

6.2 基线忠实性、固定消费者、模型版本、资源设置与统计方法。

6.3 **E1**：无效候选、有效方法保留、审核与模型成本。

6.4 **E2**：未来任务、个性化与角色差异、读取到成功漏斗。

6.5 **E3**：持续演化、冻结对照、新旧能力及累计成本。

6.6 机制消融、错误归因；区分生成错误、消费错误和验收问题。

6.7 员工试点与工业影响：如尚未开展，明确缺失，不用问卷或历史估计工时冒充。

结果图表：数据分布表；E1/E2主结果表；质量-总成本图；E3时间曲线与退化矩阵；实际人时/审核维护表。无数据不填模拟提升数字。

7. Discussion, Limitations and Lessons (约0.6页)

讨论稀疏反馈、任务歧义、偏好与政策冲突、角色受损、成本转移、授权和可披露性；解释何时应不生成、不更新或选择更简单的摘要方法。给出工业使用的可迁移经验以及未解决问题。

8. Conclusion (约0.3页)

只总结实际证据支持的方法与系统价值，不把“越用越好”愿景写成已经证明的普遍规律。

References and Reproducibility Appendix

包含近邻版本、标注规范、验收rubric、基线提示与改动、数据字段映射、分集manifest、模型/工具配置、计费口径、失败记录和可公开替代材料。核心结论所需证据应留在正文，不能全部移入附录。